

Universidad Nacional de Colombia

Entrega Final Proyecto

Grupo 05

Anna Martina Visone

Nicolás Martínez López

Miller Estiven Barrera González

Sergio Andres Castro Vargas

Problema Clasificación

Motivación


Gracias a la diversidad de variables disponibles en el dataset —incluyendo información demográfica, características de la riqueza, ubicación geográfica e indicadores socioeconómicos de cada país— queremos observar si es posible explorar si existen patrones que permitan predecir el origen de la fortuna de un billonario.



Preparación Dataset

Variable objetivo

El conjunto de datos final estuvo compuesto por 2.638 registros, con una distribución de 1.811 billonarios self-made y 827 no self-made.



Selección y simplificación de variables

Variables a eliminar

- Nombre de la persona (personName)
- Año de nacimiento (BirthDate)
- Compañías asociadas (associated_companies)
- país (country)
- fuente (source)


Variable simplificada

Además, la variable **title** contenía decenas de categorías distintas, por lo que se transformó en un conjunto de características binarias más informativas, identificando si el billonario era fundador, CEO, chairman, inversionista o emprendedor.

```
'Cofounder & Chief Technology Officer and Chairman',  
'Co-Chair and Co-CEO', 'Founder & Entrepreneur & Textiles',  
'Founder & Lead Investor & Manufacturing',  
'Founder & Entrepreneur & Mining & metals', 'Co-Chairman',  
'Cofounder and Chairman Emeritus',  
'Founder & Entrepreneur & Metals', 'Non-Executive Chairman',  
'Founder & Entrepreneur & Internet',  
'Founder & Lead Investor & gas', 'President and Chairman',  
'Founder and Chairman', 'Founder & Entrepreneur & Snacks'
```

Transformación de variables numéricas


Se analizaron las distribuciones de las variables numéricas para identificar sesgos importantes. Las variables con alta asimetría, como `cpi_country` y `tax_revenue_country_country`, fueron transformadas mediante logaritmos (`log1p`)



Naive-Bayes

Implementación

- El conjunto de datos fue dividido en 70% entrenamiento, 15% validación y 15% prueba.
- Se usó muestreo estratificado.
- las variables numéricas fueron escaladas utilizando MinMaxScaler y las variables categóricas fueron transformadas mediante One-Hot Encoding



Resultados obtenidos


```
--- Classification Report for Test Set ---
              precision    recall  f1-score   support

   False         0.33         0.96         0.49         123
    True         0.83         0.09         0.17         267

 accuracy                   0.37         390
 macro avg         0.58         0.53         0.33         390
 weighted avg         0.67         0.37         0.27         390
```

Redes Neuronales

Implementación



División Dataset



Test 15 % (~396)

Validación 15 % (~396)

Entrenamiento 70 % (~1 847)


Estratificada

Preprocesamiento Dataset

- Se eliminaron is_founder e is_entrepreneur
- Encoding ordinal de finalWorth_category (muy bajo=0 ... muy alto=4)
- Países con frecuencia < 10 agrupados en "Other"
- One-Hot Encoding: país, género, categoría, industria → 79 features totales
- StandardScaler solo a columnas numéricas continuas (binarias como is_ceo se dejaron como 0/1)

Arquitecturas

Perceptrón Multicapa



Optimizador: Adam

Learning Rate: 7×10^{-3}

Loss: Sparse Categorical CE

Epoch: 50 (EarlyStopping)

TabNet


Mecanismo de Atención

Selecciona features relevantes en cada paso mediante attention transformers (sparsemax), obteniendo interpretabilidad sin sacrificar capacidad.

Hiperparámetros


n_d / n_a:	32	Optimizador:	Adam lr = 2×10^{-2}
n_steps:	5	Batch size:	1 024
γ (gamma):	1.3	Patience:	20 epochs
mask_type:	sparsemax		

Arquitectura Tabnet



Entrenamiento y Resultados


Perceptrón Multicapa



--- Classification Report for Entire Dataset ---

	precision	recall	f1-score	support
False	0.91	0.93	0.92	827
True	0.97	0.96	0.96	1811
accuracy			0.95	2638
macro avg	0.94	0.95	0.94	2638
weighted avg	0.95	0.95	0.95	2638

TabNet




--- Classification Report for TabNet on Test Set ---

	precision	recall	f1-score	support
False	0.87	0.90	0.89	124
True	0.96	0.94	0.95	272
accuracy			0.93	396
macro avg	0.91	0.92	0.92	396
weighted avg	0.93	0.93	0.93	396

Arbol de Decisión

Implementacion


- El conjunto de datos fue dividido en 70% entrenamiento, 15% validación y 15% prueba.
- Las variables numéricas fueron escaladas utilizando MinMaxScaler y las variables categóricas fueron transformadas mediante One-Hot Encoding



Configuracion

Configuración del Modelo	Profundidad Máxima	Mín. Muestras por Hoja	Mín. Muestras para División	Exactitud (Accuracy)	Precisión	Recall	F1-Score
Árbol Simple	5	2	3	94	94	94	94
Árbol Base	20	30	60	94	94	94	94
Árbol Optimizado	10	20	30	96	96	96	96

Arbol de decision



Análisis y Comparación Modelos

Análisis del Árbol de Decisión (Decision Tree)

Principales hallazgos:

- Fue el modelo más interpretable de todos los algoritmos evaluados.
 - La educación terciaria, la esperanza de vida y la proporción de multimillonarios self-made fueron las variables más relevantes.
 - Los países con mayor capital humano tendieron a clasificarse dentro de ecosistemas orientados a la innovación.
 - Permitió identificar reglas claras que explican la pertenencia de un país a cada ecosistema de riqueza.
- Excelente capacidad explicativa e interpretación de los resultados.

Análisis de Naive Bayes

Principales hallazgos:

- Capturó correctamente las tendencias generales presentes en los datos.
- Confirmó la relación entre indicadores socioeconómicos y estructuras de generación de riqueza.
- Variables como educación, inflación y esperanza de vida mostraron capacidad predictiva.
- Su principal limitación fue la suposición de independencia entre variables, poco realista en contextos económicos.

→ Modelo simple y eficiente que validó los patrones identificados por otros métodos.

Análisis de la Red Neuronal

Principales hallazgos:

- Fue el modelo más capaz de capturar relaciones complejas y no lineales.
- Identificó interacciones entre múltiples variables económicas y sociales.
- Mostró una mejor diferenciación entre economías innovadoras, financieras y dependientes de recursos.
- Reflejó que la generación de riqueza extrema depende de múltiples factores que interactúan simultáneamente.

→ Mejor representación de los patrones estructurales presentes en el dataset.

Comparación de los Modelos

Modelo	Principal Fortaleza
Decision Tree	Interpretabilidad
Naive Bayes	Simplicidad y rapidez
Neural Network	Captura de relaciones complejas

Conclusiones del Proyecto

Association:

- Se identificaron relaciones significativas entre la estructura de generación de riqueza y los indicadores socioeconómicos.
- Las economías más diversificadas mostraron mayor estabilidad macroeconómica y mejores condiciones sociales.

Clustering:

- Se identificaron tres ecosistemas de riqueza:
 - Innovation Ecosystem
 - Rentier Paradise
 - Extractive Economy
- Los resultados evidencian que los países presentan modelos estructurales diferentes de creación de riqueza.

Classification:

- Fue posible predecir si un multimillonario es self-made o heredó su fortuna.
- La Red Neuronal obtuvo el mejor desempeño, con una precisión superior al 94%.

MINERÍA DE DATOS

Muchas gracias



Proyecto - Entrega Final