

UNAL

Avance Proyecto Asociación y Agrupación

Grupo 05


Anna Martina Visone

Nicolás Martínez López


Miller Estiven Barrera González

Sergio Andres Castro Vargas



The top-left corner features a cluster of overlapping geometric shapes. These include squares and circles in various shades of blue (light, medium, and dark) and orange. Some shapes have a diagonal line pattern, while others are solid or outlined.

REGLAS DE ASOCIACIÓN

The bottom-right corner contains another cluster of overlapping geometric shapes, similar to the top-left. It includes squares and circles in blue and orange, with some featuring diagonal line patterns and others being solid or outlined.

REGLAS DE ASOCIACIÓN

Objetivo


Identificar asociaciones estructurales entre la acumulación de riqueza y los indicadores de bienestar nacional

Queremos...


extraer reglas de asociación que vinculen sectores de generación de riqueza con indicadores sociales y económicos a nivel país.

Por ejemplo,


¿Existen patrones entre la concentración de riqueza de los billonarios y variables macroeconómicas del país, como el GDP, la educación o la esperanza de vida?

The top-left corner of the slide features a cluster of decorative geometric shapes. These include overlapping squares and circles in various shades of blue (light blue, medium blue, and dark blue). Some of these shapes have a thin black grid pattern. Overlaid on these are several orange-outlined shapes, including squares and circles, some of which are partially filled with a solid orange color.

Método 1: Algoritmo Apriorí

The bottom-right corner of the slide features a cluster of decorative geometric shapes, similar to the top-left. It includes overlapping squares and circles in various shades of blue. Some shapes have a thin black grid pattern. Overlaid on these are several orange-outlined shapes, including squares and circles, some of which are partially filled with a solid orange color.

Preparación Dataset: Apriori



Agrupación por países

Transformamos el dataset original a nivel país, consolidando variables económicas, sociales y de riqueza.

- Shares de industrias y fuentes de riqueza
- Métricas de concentración y desigualdad
- Indicadores macroeconómicos nacionales



Discretización (Bining)

Convertimos variables continuas en categorías para aplicar reglas de asociación.

- Binning cuantil estándar
- Categorías: low, mid, high
- Variables transformadas con qcut y cut



Bining Adaptativo

No todas las variables tenían la misma distribución, por lo que algunos ítems requirieron una cantidad distinta de bins.

- Variables sesgadas usaron thresholds manuales
- GDP y población aplicaron log-transform
- CPI y concentración usaron bins económicos específicos
- Variables con poca variabilidad redujeron bins automáticamente



One hot encoding

Transformamos las categorías finales en variables binarias para Apriori.

- Eliminación de categorías none y unknown
- Dataset transaccional booleano
- 79 países × 116 ítems finales

	finalWorth	category	personName	age	country	city	source	industries	country
0	211000	Fashion & Retail	Bernard Arnault & family	74.080767	France	Paris	Retail and Consumer Goods	Consumer Discretionary	
1	180000	Automotive	Elon Musk	51.767283	United States	Austin	Technology	Consumer Discretionary	
2	114000	Technology	Jeff Bezos	59.225188	United States	Medina	Technology	Technology & Telecommunications	
3	107000	Technology	Larry Ellison	78.628337	United States	Lanai	Technology	Technology & Telecommunications	
		Finance & Insurance	Warren Buffett		United States		Finance		

```
for col in final_transactional_df.columns:
    print(col)
```

```
share_consumer_discretionary_bin_is_high
share_consumer_discretionary_bin_is_low
share_consumer_discretionary_bin_is_mid
share_consumer_staples_bin_is_high
share_consumer_staples_bin_is_low
share_consumer_staples_bin_is_mid
share_energy_&natural_resources_bin_is_high
share_energy_&natural_resources_bin_is_low
share_energy_&natural_resources_bin_is_mid
share_financials_&investments_bin_is_high
share_financials_&investments_bin_is_low
share_financials_&investments_bin_is_mid
share_healthcare_bin_is_high
share_healthcare_bin_is_low
```


Ejecución Apriori

1. Dataset transaccional

Cada país fue representado como una transacción binaria utilizando One-Hot Encoding.

- 79 países
- 116 ítems categóricos
- Variables de riqueza, sectores e indicadores macroeconómicos

2. Minimum Support = 0.1

Una regla debía aparecer en al menos el 10% de los países para considerarse frecuente.


- Reduce ruido en un dataset pequeño
- Mantiene suficientes combinaciones relevantes para análisis estructural

Inicialmente se obtuvieron:

67,694 reglas de asociación



Debiamos filtrarlas...



Filtro 1 — Antecedentes

Solo se permitieron variables relacionadas con:

- Shares sectoriales
- Fuentes de riqueza
- Self-made ratio
- Concentración y riqueza



Filtro 2 — Consecuentes

Los consecuentes se limitaron a indicadores de bienestar nacional:

- Life expectancy
- CPI
- Tax revenue
- Education enrollment
- Total tax rate




Filtro 3 — Eliminación de categorías “mid”

Se eliminaron reglas con categorías intermedias (mid).

Objetivo:

Evitar reglas ambiguas y conservar asociaciones más extremas y distintivas.



Filtro 4 — Complejidad

Se restringieron las reglas a:

- Máximo 2 antecedentes
- Exactamente 1 consecuente

Objetivo:

Generar reglas más interpretables y fáciles de explicar.


Reglas encontradas

Estabilidad de Precios y Manufactura: Existe una fuerte correlación entre países con una baja participación de la industria manufacturera y la estabilidad del CPI. Esto sugiere que las economías menos dependientes de la industria pesada o manufacturera en el sector de billonarios tienden a reportar inflaciones más controladas. **Support: 0.15, Confidence: 0.90, Lift: 2.37**


Longevidad y Consumo Discrecional: Una alta presencia de riqueza en el sector de Consumo Discrecional (lujo, moda, retail premium) está vinculada a una alta esperanza de vida. Esto suele ocurrir en economías desarrolladas (como Francia o Italia) donde el mercado de consumo está maduro y los sistemas de salud son robustos. **Support: 0.11, Confidence: 0.64, Lift: 1.88**

Carga Fiscal y Finanzas: Una baja participación de billonarios provenientes del sector financiero se asocia con una tasa impositiva total alta. Esto podría reflejar estructuras estatales más grandes o países con políticas de redistribución más agresivas que desincentivan la acumulación extrema en el sector financiero puro. **Support: 0.10, Confidence: 0.56, Lift: 1.71**

Inflación Moderada y Finanzas: Cuando la riqueza proviene predominantemente de Inversiones y Finanzas y es mayoritariamente Self-Made, se observa una inflación moderada (en lugar de estable o alta). Esto sugiere un dinamismo económico que, si bien genera crecimiento, mantiene una presión constante sobre los precios. **Support: 0.10, Confidence: 0.82, Lift: 1.66**

The top-left corner of the slide features a cluster of decorative geometric shapes. These include squares and circles in various shades of blue (light, medium, and dark) and orange. Some shapes have a black grid pattern, while others are solid or have orange outlines.

Método 2: Algoritmo FP-Growth

The bottom-right corner of the slide features a cluster of decorative geometric shapes, similar to the top-left corner. It includes squares and circles in various shades of blue and orange, some with a black grid pattern and others with orange outlines.

Proceso

Transformación del Dataset

Uso del dataset binario generado previamente en el algoritmo apriori, donde cada columna representa la presencia o ausencia de una característica

Identificación de Ítems Frecuentes

Aplicación del algoritmo FP-Growth con $\text{min_support} = 0.1$ para encontrar combinaciones de atributos frecuentes en al menos el 10% de los países.

Generar Reglas de Asociación

Creación de reglas a partir de los ítems frecuentes utilizando la métrica Lift ($\text{lift} > 1$) para identificar asociaciones positivas y relevantes.

Filtrado de Antecedentes

Restricción de los antecedentes únicamente a variables relacionadas con estructura de riqueza y sectores económicos (`share_` y `selfMade_ratio_bin_`).




Filtrado de Consecuentes

Restricción de los consecuentes a indicadores de bienestar y variables macroeconómicas del país (`life_expectancy`, `cpi_change`, `impuestos`, `educación`, etc.).

Análisis de Reglas Interesantes

Evaluación y visualización de las reglas refinadas utilizando métricas como soporte, confianza y lift.

Resultados



109

Reglas Encontradas

Método 2: FP-Growth

Reglas Interesantes Identificadas

1. Baja dependencia industrial asociada con estabilidad inflacionaria y alta esperanza de vida

Antecedente: {Baja participación de riqueza proveniente de manufactura e industria}

Consecuente: {Inflación estable, Alta esperanza de vida}

Confianza: 0.80 - Lift: 2.75

El 80% de los países con baja dependencia industrial presentan simultáneamente estabilidad inflacionaria y alta esperanza de vida.

El lift elevado indica que esta asociación ocurre mucho más de lo esperado estadísticamente. Esto sugiere que economías menos industrializadas y más orientadas a servicios o tecnología tienden a mostrar mejores condiciones sociales y macroeconómicas.

2. Alta presencia tecnológica y sectores "otros" asociada a baja educación terciaria

Antecedente: {Alta participación de sectores "otros", Alta participación de riqueza tecnológica}

Consecuente: {Baja matrícula en educación terciaria}

Confianza: 0.89 - Lift: 2.60

Esta fue una de las reglas más fuertes encontradas. El 89% de los países con estas características presentan baja matrícula universitaria. El resultado puede indicar concentración de riqueza tecnológica sin una expansión equivalente del acceso a educación superior.

3. Baja dependencia industrial relacionada con estabilidad inflacionaria

Antecedente: {Baja participación de riqueza manufacturera e industrial}

Consecuente: {Inflación estable}

Confianza: 0.9 - Lift: 2.37

El 90% de los países con baja dependencia industrial presentan inflación estable. La asociación sugiere que economías menos expuestas a cadenas industriales y costos de producción presentan menor volatilidad macroeconómica.

Reglas Interesantes Identificadas

4. Baja concentración manufacturera asociada a estabilidad económica

Antecedente: {Baja concentración industrial y manufacturera, Baja riqueza proveniente de manufactura e industria}
Consecuente: {Inflación estable}

Confianza: 0.89 - Lift: 2.34

Los países con bajo peso industrial muestran frecuentemente inflación controlada. La alta confianza demuestra que la relación es consistente dentro del dataset y refuerza el patrón entre menor industrialización y estabilidad económica.

5. Baja orientación industrial vinculada a mayor esperanza de vida

Antecedente: {Baja participación de riqueza industrial}
Consecuente: {Alta esperanza de vida}

Confianza: 0.80 - Lift: 2.34

Los países menos dependientes de riqueza industrial suelen registrar mejores indicadores de bienestar social. Esto podría estar relacionado con economías más limpias, orientadas a servicios y menos expuestas a contaminación o riesgos industriales.

6. Alta presencia de sectores “otros” asociada a baja esperanza de vida y baja educación terciaria

Antecedente: {Alta participación de sectores “otros”}
Consecuente: {Baja esperanza de vida, Baja educación terciaria}

Confianza: 0.5 - Lift: 2.32

Aunque la confianza es moderada, el lift es muy alto, indicando una asociación estadísticamente importante. Los países con economías menos estructuradas o difíciles de clasificar tienden a presentar peores indicadores sociales y educativos.

Reglas Interesantes Identificadas

7. Baja presencia de sectores “otros” asociada a estabilidad económica y social

Antecedente: {Baja participación de sectores “otros”}

Consecuente: {Inflación estable, Alta esperanza de vida}

Confianza: 0.60 - Lift: 2.06

8. Riqueza self-made moderada y baja industrialización asociadas a estabilidad inflacionaria

Antecedente: {Baja concentración industrial, Proporción moderada de riqueza self-made}

Consecuente: {Inflación estable}

Confianza: 0.75 - Lift: 1.97

9. Baja participación financiera asociada a altas tasas tributarias

Antecedente: {Baja participación del sector financiero y de inversiones}

Consecuente: {Altas tasas tributarias}

Confianza: 0.56 - Lift: 1.71

10. Alta presencia tecnológica asociada a alta esperanza de vida

Antecedente: {Alta participación del sector tecnológico como fuente de riqueza}


Consecuente: {Alta esperanza de vida} Confianza: 0.5 - Lift: 1.46

Los países con estructuras económicas más definidas tienden a combinar estabilidad macroeconómica con mejores indicadores sociales. El lift superior a 2 muestra que esta relación ocurre mucho más frecuentemente de lo esperado.


Tres de cada cuatro países con estas características presentan inflación estable. Esto puede representar economías más flexibles y menos dependientes de producción industrial intensiva, favoreciendo estabilidad macroeconómica.

Los países menos dominados por sectores financieros parecen depender más de esquemas fiscales tradicionales y de una mayor carga tributaria. Esto podría estar relacionado con economías más orientadas al recaudo estatal o con menor capacidad de atraer capital financiero internacional.

Aunque la confianza es moderada, el patrón sigue siendo relevante estadísticamente. Las economías con fuerte presencia tecnológica suelen estar asociadas con mejores sistemas de salud, innovación, infraestructura y calidad de vida. Esto favorece condiciones sociales que contribuyen a una mayor esperanza de vida.

A cluster of overlapping geometric shapes in the top-left corner, including squares and circles with diagonal line patterns in various shades of blue, and orange-outlined shapes.

Agrupación

A cluster of overlapping geometric shapes in the bottom-right corner, including squares and circles with diagonal line patterns in various shades of blue, and orange-outlined shapes.

Agrupacion

Objetivo

Identificar patrones estructurales en los ecosistemas de riqueza de distintos países, utilizando características relacionadas con sus billonarios e indicadores socioeconómicos

Queremos...

Identificar grupos de países con estructuras económicas similares, considerando factores como los sectores dominantes, la riqueza self-made, la concentración industrial y distintos indicadores socioeconómicos.

Por ejemplo,

Buscamos identificar países cuya riqueza esté impulsada principalmente por tecnología, finanzas o extracción de recursos naturales, y analizar cómo estas estructuras se relacionan con variables sociales y económicas.

Mapeo de sectores

industries	
0	Consumer Discretionary
1	Consumer Discretionary
2	Technology & Telecommunications
3	Technology & Telecommunications
4	Financials & Investments
5	Technology & Telecommunications
6	Media, Entertainment & Leisure
7	Technology & Telecommunications
8	Other
9	Technology & Telecommunications
10	Consumer Discretionary
11	Technology & Telecommunications
12	Consumer Discretionary
13	Technology & Telecommunications
14	Consumer Staples



Cluster Features	
0	share_energy
1	share_finance
2	share_manufacturing
3	share_mining
4	share_other
5	share_real_estate
6	share_technology
7	hhi_concentration
8	selfMade_ratio
9	life_expectancy_country
10	gross_tertiary_education_enrollment

Variables por país

	country	share_energy	share_finance	share_manufacturing	share_mining	share_other
0	Algeria	0.0	0.000000	0.000000	0.0	1.000000
1	Andorra	0.0	1.000000	0.000000	0.0	0.000000
2	Argentina	0.0	0.750000	0.000000	0.0	0.250000
3	Armenia	0.0	1.000000	0.000000	0.0	0.000000
4	Australia	0.0	0.418605	0.093023	0.0	0.023256


Por ejemplo:

Software e internet → Tecnología

Bancos e inversiones → Finanzas



PAC

2D PCA Projection of Country Features




- Feature matrix shape: (79, 11)
PCA explained variance: PC1=20.1%, PC2=18.4%


Grafica de codo - K means



K means



Heatmap of Normalized Profiles



Objetivo del análisis

**Agrupar países según su
estructura económica**

**Detectar
patrones
similares**

**Identificar países
atípicos**

Clasificación de Ecosistemas de Riqueza

DBSCAN + Clustering Jerárquico (Ward)

DBSCAN es un algoritmo de clustering basado en densidad que permite detectar grupos naturales y países atípicos (outliers) sin definir previamente el número de clusters.

- No requiere definir k
- Detecta outliers
- Basado en densidad


El clustering jerárquico con método Ward construye una estructura en forma de árbol (dendrograma) mostrando cómo los países se agrupan progresivamente según su similitud

- Agrupamiento jerárquico
- Minimiza varianza interna
- Produce dendrograma

k-distance plot

Selección de ε

- Método k-distance
- Detección del knee point
- $\varepsilon = 2.5$



Resultados DBSCAN

- Número de clusters
- Número de outliers
- Métricas de evaluación

```
DBSCAN (epsilon=2.5, min_samples=3)
  Clusters found : 2
  Outlier countries : 8
  Silhouette Score (excl. outliers) : 0.2481
  Davies-Bouldin Index      : 0.8253
  Calinski-Marabasz Index   : 6.16


Outlier countries (noise = -1):

=== DBSCAN cluster profiles ===
      share_technology  share_finance  share_real_estate  share_energy  share_mining  share_manufacturing  selfMade_ratio  hhi_concentration  life_expectancy_country  gross_tertiary_education_enrollment
cluster_dbscan
0      0.218      0.503      0.035      0.005      0.001      0.049      0.62      0.582      77.857      58.444
1      0.000      0.000      0.000      0.000      0.000      0.000      0.00      1.000      79.647      60.800
['Austria', 'Finland', 'Greece', 'Nigeria', 'Oman', 'Russia', 'South Africa', 'Taiwan']
```

Visualización PCA

Selección de ϵ

- Cada punto = un país
- Colores = clusters
- Rojo = outliers



OUTLIERS

Países atípicos

- Qatar
- Kazakhstan
- Luxembourg
- Oman


--- Outlier country profiles ---

	share_technology	share_finance	share_real_estate	share_energy	share_mining	share_manufacturing	selfMade_ratio	hhi_concentration	life_expectancy_country	gross_tertiary_education_enrollment
country										
Austria	0.083	0.333	0.167	0.083	0.000	0.083	0.667	0.222	81.6	85.1
Finland	0.143	0.143	0.000	0.000	0.000	0.571	0.286	0.388	81.7	88.2
Greece	0.000	1.000	0.000	0.000	0.000	0.000	0.333	1.000	81.3	136.6
Nigeria	0.000	0.333	0.000	0.000	0.000	0.667	0.667	0.556	54.3	10.2
Oman	1.000	0.000	0.000	0.000	0.000	0.000	1.000	1.000	77.6	38.0
Russia	0.139	0.494	0.076	0.000	0.063	0.139	1.000	0.300	72.7	81.9
South Africa	0.200	0.400	0.000	0.000	0.200	0.000	0.600	0.280	63.9	22.4
Taiwan	0.043	0.413	0.022	0.087	0.000	0.326	0.630	0.299	78.6	66.3

These countries have unique wealth structures that do not fit any of the three main archetypes.

DENDROGRAMA

- Relaciones jerárquicas
- Similitud entre países
- Corte $\approx$ 3 clusters



Resultados Ward

- Silhouette Score
- Davies-Bouldin
- ARI vs K-Means

=== Hierarchical (k=3) metrics ===

Silhouette Score : 0.2278

Davies-Bouldin Index : 1.5881

Calinski-Harabasz Index : 14.65

Cluster sizes: {0: 49, 1: 17, 2: 13}

Comparación de algoritmos

- K-Means
- DBSCAN
- Ward

==== COMPARISON OF ALL THREE CLUSTERING ALGORITHMS ====								
k / clusters found Outliers detected Silhouette ↑ Davies-Bouldin ↓ Calinski-Harabasz ↑ Silhouette ≥ 0.50 DBI < 1.00								
Algorithm								
K-Means	3	0	0.2249	1.6968	15.75	X	X	
DBSCAN	2	8	0.2401	0.8253	6.16	X		✓
Hierarchical (Ward)	3	0	0.2278	1.5881	14.65	X	X	

MINERÍA DE DATOS

Muchas gracias

Proyecto - Avance 2

